

课程须知

➤ 本课程适用软件版本: MWORKS.Syslab2023b 1030

➤ 本课程示例运行需要软件首选项加载:

基础库(TyBase)

数学库(TyMath)

图形库(TyPlot)

统计库(TyStatistics)

MWORKS.Syslab统计工具箱应用

苏州同元软控信息技术有限公司版权所有，侵权必究。

左喆伟

苏州同元软控信息技术有限公司

2024年6月13日

目录

1. 统计工具箱功能概况


2. 概率分布与随机数

3. 描述性统计量与统计图

4. 参数估计与假设检验

5. Copula理论及应用实例

1. 统计工具箱功能概述



MWORKS统计工具箱旨在**数据处理与展示**和**数据分析**阶段提供支撑

1. 统计工具箱功能概述

1

概率分布

- 离散分布
- 连续分布
- 多元分布

2

随机数

- 概率分布随机数
- 伪随机数和拟随机数生成
- 重抽样方法

3

描述性统计量

- 中心趋势和散度
- 范围、偏差和Z分数
- 相关性和协方差

4

统计图

- 直方图
- 双标图
- 最小二乘线条

5

参数估计

- 离散分布参数估计
- 连续分布参数估计
- 多元分布参数估计

6

假设检验

- 分布检验
- 位置检验
- 散度检验

目录

1. 统计工具箱功能概况

2. 概率分布与随机数

3. 描述性统计量与统计图

4. 参数估计与假设检验

5. Copula理论及应用实例

2.1 概率分布与随机数 – 离散分布

离散概率分布是指随机变量只能取有限数量的值的概率分布。

分布类别	说明
二项分布	在 n 个独立的、同分布的随机试验中，成功次数的概率分布
几何分布	进行重复独立的 Bernoulli 试验，直到出现首次成功所需的试验次数的概率分布。
超几何分布	从 N 个物品中抽取 n 个物品，其中包含了 M 个指定的物品，所需失败物品数量的概率分布。
多项分布	在 n 次独立的、同分布的试验中，各个结果出现次数的概率分布，其中每次试验有 k 种可能结果。
负二项分布	在一系列独立的 Bernoulli 试验中，直到出现 r 次成功所需的试验次数的概率分布。
泊松分布	在一定时间内、某个事件发生次数的概率分布。
均匀分布（离散）	在有限个数的离散取值中，各个取值概率相等的概率分布。

2.1 概率分布与随机数 – 二项分布

若随机变量 X 的概率密度函数为

$$P(X=k)=C_n^k p^k (1-p)^{n-k}, \quad k=0,1,\dots,n; 0 < p < 1$$

则称 X 服从二项分布，记为 $X \sim B(n,p)$ 。其期望 $E(X)=np$ ，方差 $\text{var}(X)=np(1-p)$ 。

构造二项分布 (Binomial)

构造 $n=10, p=0.4$ 的二项分布


```
n = 10  
p = 0.4  
pd =  
Binomial(10,0.4)
```

输出

```
Binomial{Float64}(n=10,  
p=0.4)
```

生成二项分布的10000个随机数，并生成频数直方图

```
x = random(pd,10000);  
histogram(x)  
pdf(pd,3)  
# 0.21499084800000006  
pdf(pd,4)  
# 0.25082265600000002  
pdf(pd,5)  
# 0.200658124800000034
```



2.2 概率分布与随机数 – 连续分布

连续分布用于描述连续型随机变量的概率分布情况。

分布类别	说明
beta分布	定义在0到1之间的随机变量的概率分布。
卡方分布	由n个独立的标准正态分布的平方和构成的分布。
指数分布	描述随机事件间隔时间的概率分布，通常用于描述连续时间下等待时间的分布。
极值分布	极值理论的基础分布，用于描述一组随机变量中最大值或最小值的分布。
F分布	两个独立的卡方分布的比值构成的分布。
gamma分布	描述随机事件的时间间隔、随机变量的形状等。
t分布	由标准正态分布和卡方分布构成的分布，常用于小样本的统计推断。

更多连续分布请参阅Syslab - 统计工具箱帮助文档

2.2 概率分布与随机数 – 卡方分布

设随机变量 $X_1, X_2, \dots, X_k$ 相互独立, 且均服从标准正态分布, 则称随机变量

$\chi^2 = \sum_{i=1}^k X_i^2$ 所服从的分布是自由度为 k 的 χ^2 分布, 记作 $\chi^2 \sim \chi^2(k)$ 。

构造卡方分布 (Chisq)

构造自由度分别是10、20、30 的卡方分布

```
c1 = Chisq(10)
c2 = Chisq(20)
c3 = Chisq(30)
```

输出

```
Chisq{Float64}(v=10.0)
Chisq{Float64}(v=20.0)
Chisq{Float64}(v=30.0)
```


绘制卡方分布密度函数图

```
x1 = 1:0.2:30
p1 = pdf.(c1,x1)

x2 = 1:0.2:45
p2 = pdf.(c2,x2)

x3 = 1:0.2:60
p3 = pdf.(c3,x3)

plot(x1,p1,x2,p2,x3,p3)
xlabel("x")
ylabel("f(x)")
title(raw"$\chi^2$分布")
legend(["n=10", "n=20", "n=30"])
```



2.3 概率分布与随机数 – 多元分布

多元分布 (multivariate distribution) 是指在统计学中，同时考虑两个或两个以上随机变量的概率分布。

分布类别	说明
copula 分布	用于描述两个或多个随机变量的相关性。
高斯混合分布	由多个高斯分布按照一定的权重混合而成。
逆 Wishart 分布	多元矩阵分布，用于描述协方差矩阵的不确定性。
多元正态分布	多元随机变量的联合分布。
多元 t 分布	多元正态分布的扩展，可以描述具有长尾特征的数据分布。
Wishart 分布	多元矩阵分布，用于描述协方差矩阵的不确定性。



2.4 概率分布与随机数 - 概率密度、分布和逆概率分布数值计算

一、功能函数

统计工具箱提供一系列函数，函数名以 **pdf** 三个字符结尾的函数用来计算常见连续分布的**密度函数值**或离散分布的**概率函数值**，函数名以 **cdf** 三个字符结尾的函数用来计算常见分布的**分布函数值**，函数名以 **inv** 三个字符结尾的函数用来计算常见分布的**逆概率分布函数值**。

离散分布	连续分布		
二项分布 (bino)	正态分布 (norm)	t 分布 (t)	威布尔分布 (wbl)
负二项分布 (nbin)	对数正态分布 (logn)	非中心 t 分布 (nct)	瑞利分布 (rayl)
几何分布 (geo)	多元正态分布 (mvn)	多元 t 分布 (mvt)	极值分布 (ev)
超几何分布 (hyge)	连续均匀分布 (unif)	F 分布 (f)	广义极值分布 (gev)
泊松分布 (poiss)	指数分布 (exp)	非中心F分布 (ncf)	广义 Pareto 分布 (gp)
离散均匀分布 (unid)	卡方分布 (chi2)	β 分布 (beta)	
多项分布 (mn)	非中心卡方分布 (ncx2)	Γ 分布 (gam)	

2.4 概率分布与随机数 - 概率密度、分布和逆概率分布数值计算

一、功能函数

示例： 求标准正态分布、t 分布、 χ^2 分布和F分布的**上侧分位数**

上侧分位数： 设随机变量 $\chi^2 \sim \chi^2(n)$,对于给定 $0 < a < 1$, 称满足 $P(\chi^2 \geq \chi_a^2) = a$ 的数 χ_a^2 为 $\chi^2(n)$ 分布的上侧 a 分位数。

①标准正态分布的上侧0.05分位数 $u_{0.05}$

②自由度为50的t分布的上侧0.05分位数
 $t_{0.05}(50)$

③自由度为8的 χ^2 分布的上侧0.025分位数
 $\chi_{0.025}^2(8)$

④第一自由度为7，第二自由度为13的F分布
的上侧0.01分位数 $F_{0.01}(7,13)$

⑤第一自由度为13，第二自由度为7的F分布
的上侧0.01分位数 $F_{0.99}(13,7)$

公式

$u = \text{norminv}(1-0.05,0,1)$

$t = \text{tinv}(1-0.05,50)$

$\text{chi2} = \text{chi2inv}(1-0.025,8)$

$f1 = \text{finv}(1-0.01,7,13)$

$f2 = \text{finv}(1-0.99,13,7)$

输出

1.6448536269514717

1.675905025163097

17.53454613948465

4.440997410665112

0.22517464153401376

2.4 概率分布与随机数 - 概率密度、分布和逆概率分布数值计算

二、通用函数

统计工具箱还提供了 **pdf**、**cdf**、**icdf** 三个公共函数用来计算常见分布的概率密度、分布和逆概率分布函数值。

密度函数		分布函数		逆概率分布函数	
函数名	调用格式	函数名	调用格式	函数名	调用格式
cdf	cdf(pd,x)	pdf	pdf(pd,x)	icdf	icdf(pd,x)

示例：求服从均值为1.2345，标准差（方差的算术平方根）为 6 的正态分布随机变量 X 在 $x = 0, 1, 2, \dots, 5$ 处的密度函数值与分布函数值，并求概率 $P(-2 < X \leq 5)$ 。

```
x = 0:5  
# 定义一个向量
```

```
pd = Normal(1.2345,6)  
# 定义正态分布
```

```
y = pdf.(pd,x)  
# 求密度函数值
```

6-element
Vector{Float64}:
0.06509779940232067
0.06643961719588705
0.06595142743156684
0.06367332692530846
0.05978980669033623
0.05460507659780878

```
f = cdf.(pd,x)  
# 求分布函数值
```

6-element
Vector{Float64}:
0.41849309983938565
0.48441197444484896
0.5507606392978752
0.6157165618166252
0.6775708031195895
0.7348615351656139

```
p = cdf(pd,5) - cdf(pd,-2)  
# 求概率
```


0.4399468575827188

2.4 概率分布与随机数 – 随机数

一、常见一元分布随机数


示例1：调用 `normrnd` 函数生成 10000×3 的正态分布随机数矩阵，其中均值 $\mu = 75$ ，标准差 $\sigma = 8$ ，并作出各列的频数直方图。

```
x = normrnd(75,8,1000,3)
hist(x)
xlabel("正态分布随机数( $\mu = 75, \sigma = 8$ )")
ylabel("频数")
legend(["第一列", "第二列", "第三列"])
```



示例2：调用 `normrnd` 函数生成 10000×3 的正态分布随机数矩阵，其中各列均值 μ 分别为0、15、40，标准差 σ 分别为1、2、3，并作出各列的频数直方图。

```
x = [normrnd(0,1,1000) normrnd(15,2,1000) normrnd(40,3,1000)]
hist(x,50)
xlabel("正态分布随机数")
ylabel("频数")
legend([" $\mu = 0, \sigma = 1$ ", " $\mu = 15, \sigma = 2$ ", " $\mu = 40, \sigma = 3$ "])
```




2.4 概率分布与随机数 – 随机数

二、生成多元分布随机数


示例1：调用mnrnd函数生成 10000 组3项分布随机数，并利用 hist3 函数做出前两列的频数直方图。其中3项分布的参数为 $n=100, p=[0.2, 0.3, 0.5]$ 。

```
n = 100
p = [0.2, 0.3, 0.5]
r = mnrnd(n, p, 10000)
hist3(r[:, 1:2], [10, 10])
plt_view([-66, 22])
xlabel(raw"$X_1$")
ylabel(raw"$X_2$")
zlabel("频数")
```



示例2：调用 mvnrnd 函数生成 10000 组2元正态分布随机数，并利用 hist3 函数做出频数直方图。其中分布的参数为 $\mu = [10, 20]$, $\sigma = [1 \ 3; 3 \ 16]$ 。

```
 $\mu = [10, 20]$ 
 $\sigma = [1 \ 3; 3 \ 16]$ 
xy = mvnrnd( $\mu$ ,  $\sigma$ , 10000)
hist3(xy, [10, 10])
plt_view([-66, 22])
xlabel("X")
ylabel("Y")
zlabel("频数")
```



目录

1. 统计工具箱功能概况

2. 概率分布与随机数

3. 描述性统计量与统计图

4. 参数估计与假设检验

5. Copula理论及应用实例

3.1 描述性统计量与统计图 – 描述性统计量

描述性统计量是用于总结和描述数据集的数值特征的统计量。它们提供了关于数据集的中心趋势、离散程度和分布形状的信息。

函数	说明
均值 (mean)	所有观察值的总和除以观察值的数量，用于衡量数据的中心趋势。
方差 (var)、标准差 (std)	衡量数据的离散程度，表示观察值与平均值之间的差异程度。值越大，数据集的观察值越分散。
中位数 (median)	将数据集按照大小排序，位于中间位置的观察值，用于衡量数据的中心趋势。当数据集中存在极端值或偏斜时，中位数通常比平均值更能代表数据的中心位置。
分位数 (prctile)	将数据集按大小排序后，将观察值分为百分比。例如，第25百分位数是将数据集分为四个部分时位于第一个部分末尾的观察值，用于衡量数据的分布形状。
峰度 (kurtosis)	反映了总体分布密度曲线在其峰值附近的陡峭程度。
偏度 (skewness)	反映了总体分布的对称性信息，偏度越接近于0，说明分布越对称，否则分布越偏斜。

更多描述性统计量请参阅Syslab - 统计工具箱帮助文档



3.1 描述性统计量与统计图 - kurtosis

峰态是衡量分布的离群倾向程度的指标。正态分布的峰度为 3。比正态分布更容易出现离群值的分布峰度大于 3；不太容易出现离群值的分布的峰度小于 3。

kurtosis 计算此总体值的样本数据，峰度公式定义为 $k = \frac{E(x-\mu)^4}{\sigma^4}$ ，且根据 flag 设置不同，公式不同：

示例

示例1：计算正态分布随机数的峰度：

```
# 生成 10000 个正态分布随机数
rng = MT19937ar(5489)
x = randn(rng, 10000);

# 计算峰度
x = kurtosis(x)
```

输出：

```
1-element Vector{Float64}:
 3.030779562325225
```

示例2：沿第一维度计算数据的峰度：

```
rng = MT19937ar(5489)
x = randn(rng, 4, 3, 2);
```

输出：

```
4×3×2 Array{Float64, 3}:
[:, :, 1] =
 0.537667  0.318765  3.5784
 1.83389  -1.30769  2.76944
-2.25885  -0.433592 -1.34989
 0.862173  0.342624  3.03492

[:, :, 2] =
 0.725404  -0.124144  0.671497
-0.0630549  1.4897   -1.20749
 0.714743  1.40903   0.717239
-0.204966  1.41719   1.63024
```

flag 为 1 时，峰度有偏差，适用以下等式：

$$k1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right)^2}$$

flag 为 0 时，校正系统偏差，适用以下等式：

$$k0 = \frac{n-1}{(n-2)(n-3)} ((n+1)k_1 - 3(n-1)) + 3$$

这个偏差校正方程要求 X 至少包含四个元素。

```
k1 = kurtosis(x)
```

输出：

```
1×3×2 Array{Float64, 3}:
[:, :, 1] =
 2.13498  1.70599  2.27889

[:, :, 2] =
 1.0542  2.3278  2.09958
```


3.1 描述性统计量与统计图 - trimmean

trimmean - 修剪均值是对数据样本位置的稳健估计。如果数据包含离群值，则修剪均值比样本均值更能代表数据的中心。但是，如果所有数据都来自相同的概率分布，则作为数据位置的估计量，修剪均值不如样本均值有效。

示例

示例：控制异常值分布的修整：

```
# 从自由度为 1 学生 t 分布生成随机  
# 数向量。学生 t 分布往往具有离群值。  
rng = MT19937ar(5489)  
nu = 1  
n = 60  
x = trnd(rng,nu,n);  
normplot(x)
```



尽管分布围绕零对称，但有几个离群值会影响均值。找出数据的平均值。

```
mn = mean(x)
```

输出：

```
1.6452317776330925
```

找出数据的 33% 修剪平均值。

```
trim = trimmean(x,33)
```

输出：

```
0.49399784569189836
```

对于 33% 的修剪平均值，k不是整数 (k = 60*(33/100)/2给出的值为9.9)。指定“ floor”向下舍入到下一个更小的整数来控制修剪。

```
trim = trimmean(x,33,"floor")
```

输出：

```
0.4933065731549443
```

3.2 描述性统计量与统计图 – 统计图

统计图是用于可视化和分析数据集的不同方面。

函数	说明
正态概率图 (normplot)	用于正态分布的检验。
双标图 (biplot)	结合了主成分分析 (PCA) 的结果和原始数据的信息，可视化多元数据集的图形工具。
最小二乘线条 (lsline)	向散点图添加最小二乘线条。
添加参考曲线 (refcurve)	将带有系数的多项式参考曲线添加至图中。
累积经验分布图 (ecdf)	目标数据的经验累积分布图。
威布尔概率图 (wblplot)	比较数据与Weibull 分布的图。

更多统计图请参阅Syslab - 统计工具箱帮助文档



3.2 描述性统计量与统计图 - ecdf

ecdf - 计算经验累积分布函数 (Empirical Cumulative Distribution Function, ECDF)。


ECDF 是一种用于描述一组数据的经验分布的非参数方法。

示例

示例：将经验 cdf 与已知 cdf 进行比较：

```
# 从平均失效时间为 15 的指数分布生成失效时间。
rng = MT19937ar(5489)
y = exprnd(rng,15,75)
# 从平均失效时间为 30 的指数分布生成退出时间。
d = exprnd(rng,30,75)
# 生成观察到的故障次数，即生成的故障次数和退出次数中的最小值。
t = min.(y,d)
# 创建一个逻辑数组，其中包含大于退出时间的生成故障时间。此条件为真的数据将被审查。
censored = y.>d
# 绘制经验 cdf 和置信区间。
ecdf(t,Censoring=censored,Bounds="on",plot=true)

# 叠加已知 cdf 的图
hold("on")
xx = 0:.1:maximum(t);
yy = 1.-exp.(-xx/15);
plot(xx,yy,"g-",linewidth=2)
```



3.2 描述性统计量与统计图 - wblplot

wblplot – Weibull概率图，用于直观地确定数据是否来自Weibull分布。

示例


示例：威布尔分布检验：生成两个样本数据集，一个来自 Weibull 分布，另一个来自对数正态分布。执行 Lilliefors 测试以评估每个数据集是否来自 Weibull 分布。通过使用 Weibull 概率图 (wblplot) 进行视觉比较来确认测试决策。

```
# 从 Weibull 分布生成样本。
rng = MT19937ar(5489)
data1 = wblrnd(rng,2,0.5,500);
# 使用 lillietest 执行 Lilliefors 测试。
h1 = lillietest(log.(data1),0.05,"ev")
```

输出：

0.0

wblplot
(data1)




```
# 从对数正态分布生成样本。
rng = MT19937ar(5489)
data2 = lognrnd(rng,5,2,500);
# 使用 lillietest 执行 Lilliefors 测试。
h2 = lillietest(log.(data2),0.05,"ev")
```

输出：

1.0

wblplot
(data2)



目录

1. 统计工具箱功能概况

2. 概率分布与随机数

3. 描述性统计量与统计图

4. 参数估计与假设检验

5. Copula理论及应用实例

4.1 参数估计与假设检验 - 参数估计

统计工具箱中有这样一系列函数，函数名以 **fit** 三个字符结尾，这些函数用来求常见分布的参数最大似然估计和置信区间估计。

函数名	说明
betafit	β 分布的参数估计
binofit	二项分布的参数估计
evfit	极值分布的参数估计
expfit	指数分布的参数估计
fitdist	分布的拟合
gamfit	Γ 分布的参数估计
gevfit	广义极值分布的参数估计
gpfid	广义 Pareto 分布的参数估计

函数名	说明
lognfit	对数正态分布的参数估计
mlecov	最大似然估计的渐进协方差矩阵
nbinfit	负二项分布的参数估计
normfit	正态分布的参数估计
poissfit	泊松分布的参数估计
raylfid	瑞利 (Rayleigh) 分布的参数估计
unifit	均匀分布的参数估计
wblfit	威布尔 (Weibull) 分布的参数估计

4.1 参数估计与假设检验 - 参数估计

在很多实际问题中，为了进行某些统计推断，需要确定总体所服从的分布，通常根据问题的实际背景或适当的统计方法可以判断总体分布的类型，但是总体分布中往往含有未知参数，需要用样本观测数据进行估计。

常见分布的参数估计

示例：从某厂生产的滚珠中随机抽取10个，测得滚珠的直径（单位：mm）如下：

15.14 14.81 15.11 15.26 15.08 15.17 15.12 14.95 15.05 14.87

若滚珠直径服从正态分布 $N(\mu, \sigma^2)$ ，其中 μ , σ 未知，求 μ , σ 的最大似然估计和置信水平为90%的置信区间。

统计工具箱中的normfit函数用来根据样本观测值求正态总体均值 μ 和标准差 σ 的最大似然估计和置信区间，对于本例，调用方法如下：

```
x=[15.14 14.81 15.11 15.26 15.08 15.17 15.12 14.95 15.05 14.87]
muHat,sigmaHat,muci,sigmaci=normfit(x,0.1)
```

输出：

```
muHat = 15.056000000000003
sigmaHat = 0.139698087157826
muci = [14.975019644143865; 15.13698035585614;;]
sigmaci = [0.10188837984010779; 0.22983095413956786;;]
```

4.1 参数估计与假设检验 - 假设检验

统计工具箱提供参数化假设检验和非参数化假设检验，帮助您确定样本数据是否来自具有特定特征的总体。现已支持的假设检验函数列表如下：

分布检验函数名	说明
adtest	Anderson-Darling检验
chi2gof	卡方拟合优度检验
dwtest	带有剩余输入的 Durbin-Watson 检验
fishertest	费希尔精确检验
jbtest	Jarque-Bera检验
kstest	单样本 Kolmogorov-Smirnov 检验
kstest2	双样本 Kolmogorov-Smirnov 检验
lillietest	Lilliefors 检验
runstest	数据随机性检验

位置检验函数名	说明
friedman	弗里德曼检验
ranksum	Wilcoxon秩和检验
sampsizepwr	样本大小与检验功效
signrank	Wilcoxon 符号秩检验
signtest	符号检验
ttest	单样本和配对样本 t 检验
ttest2	双样本 t 检验
ztest	z检验

散度检验函数名	说明
ansaribradley	Ansari-Bradley 检验
barttest	巴特利特检验
vartest	卡方方差检验
vartest2	等方差的双样本 F 检验

4.2 参数估计与假设检验 - 正态总体参数的检验

假设检验是统计推断的另一个重要内容，同参数估计一样，在统计学的理论和实际应用中都占有重要地位。假设检验的基本功能是根据样本所提供的信息，对总体的某些方面（如总体的分布类型、参数的性质等）做出判断。

总体标准差未知时的单个正态总体均值的 t 检验

示例：化肥厂用自动包装机包装化肥，某日测得 9 包化肥的质量（单位：kg）如下：

49.4 50.5 50.7 51.7 49.8 47.9 49.2 51.4 48.9

设每包化肥的质量服从正态分布，是否可以认为每包化肥的平均质量为 50 kg？取显著性水平 $\alpha = 0.05$

分析：这是总体标准差未知时的单个正态总体均值的检验，根据题目要求可以写出如下假设：

$$H_0: \mu = \mu_0 = 50, \quad H_1: \mu \neq \mu_0$$

统计工具箱中的 ttest 函数可以用来作总体标准差未知时的正态总体均值的检验。对于本例，做如下调用：

```
# 定义样本观测值向量
x=[49.4 50.5 50.7 51.7 49.8 47.9 49.2 51.4 48.9]
mu0 = 50          # 原假设中的mu0
Alpha = 0.05      # 显著性水平alpha
# 调用ttest函数作总体均值的双侧检验
# 返回变量h, 检验的p值, 均值的置信区间muci, 结构体变量stats
h,p,muci,stats = ttest(x,mu0,alpha=Alpha)
```

输出：

```
h = [0.0;;]
p = [0.8960692177320176;;]
muci = [48.99434531229235, 50.89454357659652]
stats = TyStatistics.Ttest{Matrix{Float64}, Matrix{Int64}}
    tstat: Array{Float64}((1, 1)) [-0.1348399724926694;;]
    df: Array{Int64}((1, 1)) [8;;]
    sd: Array{Float64}((1, 1)) [1.2360330811826112;;]
```

4.3 参数估计与假设检验 - 常用非参数检验

非参数检验是一种假设检验方法，与参数检验相对。在参数检验中，我们通常对总体分布假设特定的参数，并基于样本统计量进行假设检验。而非参数检验则不对总体分布的参数作出特定的假设，而是根据样本数据的秩或排名等非参数量来进行假设检验。

Wilcoxon 符号秩检验

示例：本例参考自马逢时编著的《六西格玛管理统计指南》。抽查精细面粉的装包重量，抽查了16包，其观测值（单位：kg）如下：

20.21 19.95 20.15 20.07 19.91 19.99 20.08 20.16 19.99 20.16 20.09 19.97 20.05 20.07 19.96 20.06

检验重量的中位数与原来设定的 20 kg 是否有显著差别，取显著性水平 $\alpha = 0.05$ 。根据题目要求可以写出如下假设：

$$H_0: \mu = \mu_0 = 20, \quad H_1: \mu \neq \mu_0$$

调用 signrank 函数求解本例的 Syslab 命令如下：

```
x=[20.21 19.95 20.15 20.07 19.91 19.99  
20.08 20.16 19.99 20.16 20.09 19.97 20.05  
20.27 19.96 20.06] # 样本观测值  
p,h,stats = signrank(x,20) # 符号秩检验
```

输出：

```
p = 0.029763652470061304  
h = true  
stats = TyStatistics.Signrank  
signedrank: Float64 110.0 # Wilcoxon符号秩统计量  
zval: Float64 2.173221471977732 # 近似正态统计量
```

由于 signrank 函数返回的检验的 p 值 $p=0.0298 < 0.05$ ，所以在显著性水平 $\alpha=0.05$ 下拒绝原假设，不能认为此组面粉数据的中位数为 20。

目录

1. 统计工具箱功能概况

2. 概率分布与随机数

3. 描述性统计量与统计图

4. 参数估计与假设检验

5. Copula理论及应用实例

5.1 Copula理论及应用实例 - Copula函数的定义与性质

一. Copula函数的定义

在统计学和概率论中，copula（联合分布函数）是一种用于描述多维随机变量之间依赖结构的函数。Copula函数的定义不依赖于边缘分布函数，而是将边缘分布函数与多维联合分布函数的关系分离开来。这种分离使得研究变量之间的相关性和依赖性变得更加方便。

给定 n 个随机变量的边缘分布函数 $F_1, F_2, \dots, F_n$ ，它们的联合分布函数可以表示为 $C(u_1, u_2, \dots, u_n)$ ，其中 $u_1 = F_1(x_1), u_2 = F_2(x_2), \dots, u_n = F_n(x_n)$ ， $(x_1, x_2, \dots, x_n)$ 为 n 个随机变量的取值。Copula函数 C 的定义如下：

$$C(u_1, u_2, \dots, u_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$$

其中 $X_1, X_2, \dots, X_n$ 是具有边缘分布函数 $F_1, F_2, \dots, F_n$ 的随机变量。Copula函数 C 的输入是边缘分布函数的值，输出是联合分布函数的值。

5.1 Copula理论及应用实例 - Copula函数的定义与性质

二. Copula函数的性质

- **边缘一致性 (Marginal Uniformity)** : Copula函数在每个维度上的边缘分布都是均匀分布, 即 $C(u, 1, \dots, u, 0, \dots, u) = u$, 其中 u 是0到1之间的任意数值。
- **边缘分布函数的一致性 (Marginal Distribution Consistency)** : 给定边缘分布函数 $F_1, F_2, \dots, F_n$ 和Copula函数 C , 通过Copula函数和边缘分布函数可以重构出联合分布函数: $C(F_1(x_1), F_2(x_2), \dots, F_n(x_n)) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$ 。
- **依赖性结构刻画 (Dependence Structure Characterization)** : Copula函数用于刻画多维随机变量之间的相关性和依赖性结构, 它能够独立于边缘分布函数而表示联合分布函数。
- **介于0和1之间 (Bounds)** : Copula函数的取值范围是 $[0, 1]$, 即 $0 \leq C(u_1, u_2, \dots, u_n) \leq 1$, 对于任意的 $(u_1, u_2, \dots, u_n)$ 。

这些性质使得Copula函数在建模多维随机变量的相关性和依赖性时非常有用, 它可以用于风险管理、金融建模、极值理论等领域。

5.1 Copula理论及应用实例 - 常用的Copula函数与相关度量

一. 常用的Copula函数

- **Gaussian Copula:** 高斯Copula是最常用的Copula函数之一，它基于多元正态分布的依赖性结构。高斯Copula函数具有简单的形式，并且容易处理。然而，它假设变量之间的依赖关系是线性的，对于非线性依赖结构可能不适用。
- **Student's t Copula:** 学生t Copula是一种基于学生t分布的Copula函数。相比于高斯Copula，学生t Copula对于极端事件有更好的建模能力，因为它具有更重的尾部。
- **Archimedean Copula:** Archimedean Copula是一类基于Archimedean生成函数的Copula函数。它们具有简单的形式和易于计算的性质。常见的Archimedean Copula函数包括Clayton Copula、Gumbel Copula和Frank Copula。
- **Clayton Copula:** Clayton Copula是一种常用的Archimedean Copula函数，它具有右偏依赖结构。Clayton Copula的依赖性集中在较小的值区域，对于捕捉尾部依赖性较弱。
- **Gumbel Copula:** Gumbel Copula是另一种常见的Archimedean Copula函数，它具有左偏依赖结构。Gumbel Copula的依赖性集中在较大的值区域，对于捕捉尾部依赖性较弱。

5.1 Copula理论及应用实例 - 常用的Copula函数与相关度量

二. Copula函数与相关度量

这些相关度量可以帮助我们评估Copula函数对于变量之间依赖关系的拟合程度，并进行模型选择和比较。

在评估Copula函数的依赖性时，常用的相关度量包括：

- **Kendall's Tau:** Kendall's Tau是一种非参数的相关度量，用于衡量变量之间的依赖关系的顺序。它衡量的是变量在联合分布中出现顺序相同的概率，取值范围为 $[-1, 1]$ ，其中1表示完全正相关，-1表示完全负相关，0表示无相关性。
- **Spearman's Rho:** Spearman's Rho是另一种常用的非参数相关度量，它基于变量的秩次而不是原始值。Spearman's Rho的取值范围也是 $[-1, 1]$ ，具有类似于Kendall's Tau的解释。
- **Pearson's Correlation Coefficient:** Pearson's相关系数是一种常用的参数相关度量，它衡量的是变量之间的线性相关性。它的取值范围为 $[-1, 1]$ ，其中1表示完全正相关，-1表示完全负相关，0表示无相关性。

5.1 Copula理论及应用实例 - 沪深股市日收益率的二元Copula模型

案例描述： 现有上海和深圳股市同时期日开盘价、最高价、最低价、收盘价、收益率等数据，跨度为2000-1—2007-4，各1696组数据。

收益率=（收盘价-开盘价）/开盘价

日期	开盘价	最高价	最低价	收盘价	收益率
2000/1/4	1368.69	1407.52	1361.21	1406.37	0.027529974
2000/1/5	1407.83	1433.78	1398.32	1409.68	0.001314079
2000/1/6	1406.04	1463.96	1400.25	1463.94	0.041179483
2000/1/7	1477.15	1522.83	1477.15	1516.6	0.026706834
2000/1/10	1531.71	1546.72	1506.4	1545.11	0.008748392
2000/1/11	1547.68	1547.71	1468.76	1479.78	-0.043872118
2000/1/12	1473.76	1489.28	1435	1438.02	-0.024250896
2000/1/13	1437.45	1444.07	1418.81	1424.44	-0.00905075
2000/1/14	1426.22	1433.47	1401.71	1408.85	-0.012179047
2000/1/17	1408.99	1433.38	1402.66	1433.33	0.017274785
2000/1/18	1436.89	1443.59	1421.64	1426.62	-0.007147381
2000/1/19	1425.87	1443.67	1425.14	1440.72	0.010414694
2000/1/20	1443.09	1466.9	1443.09	1466.86	0.016471599
2000/1/21	1471.91	1476.46	1458.93	1465.09	-0.004633435
2000/1/24	1465.86	1477.41	1449.47	1477.34	0.00783158
2000/1/26	1477.3	1482.46	1469.98	1481.12	0.002585798
2000/1/27	1490.45	1506.92	1485.23	1506.77	0.010949713
2000/1/28	1514.56	1536.35	1510.75	1535	0.013495669
2000/2/14	1591.45	1674.13	1587.82	1673.94	0.051833234
2000/2/15	1709.22	1746.44	1663.01	1670.67	-0.022554148

沪市开盘价、最高价、最低价、收盘价、收益率等数据

日期	开盘价	最高价	最低价	收盘价	收益率
2000/1/4	3374.11	3512.3	3360.21	3497.06	0.036439239
2000/1/5	3500.13	3589.18	3468.69	3486.28	-0.003956996
2000/1/6	3475.46	3663.22	3454.35	3655.2	0.051716895
2000/1/7	3701.48	3848.06	3701.48	3828.04	0.034191729
2000/1/10	3881.75	3929.06	3832.2	3921.48	0.010235074
2000/1/11	3924.71	3931.08	3691.56	3716.78	-0.052979711
2000/1/12	3699.29	3768.14	3585.47	3605.82	-0.025267011
2000/1/13	3604.28	3637.68	3552.05	3580.98	-0.006464537
2000/1/14	3582.16	3609.19	3524.51	3542.82	-0.010982201
2000/1/17	3535.51	3597.77	3496	3594.65	0.016727431
2000/1/18	3601.88	3633.11	3558.86	3571.97	-0.008303997
2000/1/19	3560.59	3640.09	3559.94	3603.86	0.01215248
2000/1/20	3608.17	3670.19	3603.99	3668.84	0.016814618
2000/1/21	3687.19	3744.27	3644.08	3702.09	0.004041018
2000/1/24	3709.19	3736.43	3646.17	3734.73	0.0068856
2000/1/26	3718.13	3754.1	3700.66	3737.99	0.005341395
2000/1/27	3782.89	3855.35	3754.1	3844.97	0.016410734
2000/1/28	3889.14	3952.41	3869.42	3952.41	0.016268378
2000/2/14	4102.65	4323.35	4096.46	4322.37	0.053555629
2000/2/15	4442.12	4578.62	4343.58	4394.69	-0.010677334

深市开盘价、最高价、最低价、收盘价、收益率等数据



5.1 Copula理论及应用实例 - 沪深股市日收益率的二元Copula模型

```
# X为沪市收益率数据
# Y为深市收益率数据
# 计算X和Y的偏度
xs = skewness(X)
ys = skewness(Y)
# 计算X和Y的峰度
kx = kurtosis(X)
ky = kurtosis(Y)
```

输出



```
xs = -0.025299870959816232
ys = -0.0035542561930184194
kx = 6.377426676720204
ky = 6.63394195800614
```

通过x, y的偏度、峰度反映出：随机变量x, y的分布均是比较对称的，并且呈现出尖峰厚尾的特点。正态分布是薄尾分布，因此可以初步判断不服从正态分布。

5.1 Copula理论及应用实例 - 沪深股市日收益率的二元Copula模型

对X进行正态性检验

- Jarque-Bera检验

```
h,p = jbtest(X)
```

输出

```
h = 1.0  
p = 0.001
```

对Y进行正态性检验

- Jarque-Bera检验

```
h,p = jbtest(Y)
```

输出

```
h = 1.0  
p = 0.001
```

- Kolmogorov-Smirnov检验
- 三种检验的h值均为1，p值均小于0.01，说明X和Y都不服从正态分布，而是服从某种对称的尖峰厚尾分布。遗憾的是，常见分布中难以找到这种类型的分布。下面利用非参数法确定X、Y的分布

```
h,p = kstest(X,CDF=[X  
normcdf(X,mean(X),std(X))])
```

输出

```
h = 1.0  
p = 9.280148950112244e-7
```

```
h,p = kstest(Y,CDF=[Y  
normcdf(Y,mean(Y),std(Y))])
```

输出

```
h = 1.0  
p = 4.846716110589848e-6
```

- Lilliefors检验

```
h,p, = lillietest(X)
```

输出

```
h = 1  
p = 0.001
```

- Lilliefors检验

```
h,p, = lillietest(Y)
```

输出

```
h = 1  
p = 0.001
```


5.1 Copula理论及应用实例 - 沪深股市日收益率的二元Copula模型

当总体的分布不好确定时，可以调用ecdf函数求样本经验分布函数，作为总体分布函数的近似。



```
# 调用ecdf函数求 X 和 Y 的经验分布函数
fx, Xsort = ecdf(X)
fy, Ysort = ecdf(Y)
U1 = spline(Xsort[2:end],fx[2:end],X)
V1 = spline(Ysort[2:end],fy[2:end],Y)
```

ecdf 返回的向量 Xsort 和 Ysort 是各自经过排序后的样本数据，fx 和 fy 是分别与向量 Xsort 和 Ysort 对应的经验分布函数值向量。为了求原始样本（未经排序的样本）观测值对应的经验分布函数值，上面用到了样条插值法。

```
Xsort = sort(X)
id = sortperm(X)
figure()
plot(Xsort,U1[id],linewidth=2)
legend("经验分布函数",loc="northwest")
xlabel("沪市日收益率")
ylabel("F(x)")
```

```
Ysort = sort(Y)
id = sortperm(Y)
figure()
plot(Ysort,V1[id],linewidth=2)
legend("经验分布函数",loc="northwest")
xlabel("深市日收益率")
ylabel("F(x)")
```

绘制经验分布函数图



5.1 Copula理论及应用实例 - 沪深股市日收益率的二元Copula模型

选取二元正态Copula，用核分布估计求随机变量X，Y的边缘分布，然后调用copulafit函数估计Copula中的参数，命令如下：

```
U = ksdensity(X,X;function="cdf")
V = ksdensity(Y,Y;function="cdf")
rho_norm = copulafit("Gaussian",[U(:) V(:)])
rho_t,nuhat,nuci = copulafit("t",[U(:) V(:)])
```



```
rho_norm=
2×2 Matrix{Float64}:
 1.0      0.926423
 0.926423  1.0
```

```
rho_t =
2×2 Matrix{Float64}:
 1.0      0.932539
 0.9325389  1.0
nuhat = 4.008923393
nuci =
1×2 Matrix{Float64}:
 2.983818
 5.034029
```

得到的二元正态Copula中的线性相关系数 ρ 的估计值为：

$$\hat{\rho}_{\text{norm}} = \begin{pmatrix} 1.0000 & 0.9264 \\ 0.9264 & 1.0000 \end{pmatrix}$$

得到估计的二元正态Copula：

$$\hat{C}^{\text{Ga}}(\hat{u}, \hat{v}) = \int_{-\infty}^{\Phi^{-1}(\hat{u})} \int_{-\infty}^{\Phi^{-1}(\hat{v})} \frac{1}{2\pi\sqrt{1-0.9264^2}} \exp\left\{-\frac{s^2 - 2 \times 0.9264st + t^2}{2 \times (1-0.9264^2)}\right\} ds dt$$

二元t-Copula中的线性相关参数 ρ 和自由度 k 的估计值：

$$\hat{\rho}_t = \begin{pmatrix} 1.000 & 0.9325 \\ 0.9325 & 1.0000 \end{pmatrix}, \hat{k} = 4.0089 \approx 4$$

得到估计的二元t-Copula：

$$\hat{C}^t(\hat{u}, \hat{v}) = \int_{-\infty}^{t_4^{-1}(\hat{u})} \int_{-\infty}^{t_4^{-1}(\hat{v})} \frac{1}{2\pi\sqrt{1-0.9325^2}} \left[1 + \frac{s^2 - 2 \times 0.9325st + t^2}{4 \times (1-0.9325^2)}\right]^{-(4+2)/2} ds dt$$

5.1 Copula理论及应用实例 - 沪深股市日收益率的二元Copula模型

调用corr函数求Kendall秩相关系数、Spearman秩相关系数的估计

- 直接根据沪、深两市日收益率的原始观测数据，调用corr函数求Kendall秩相关系数

```
Kendall = corr([X Y],type="Kendall")
```

输出



```
Kendall =  
2x2 Matrix{Float64}:  
 1.0      0.757242  
 0.757242  1.0
```

- 直接根据沪、深两市日收益率的原始观测数据，调用corr函数求Spearman秩相关系数

```
Spearman = corr([X Y],type="Spearman")
```

输出



```
Spearman =  
2x2 Matrix{Float64}:  
 1.0      0.912626  
 0.912626  1.0
```


5.1 Copula理论及应用实例 - 沪深股市日收益率的二元Copula模型

- 求二元正态Copula对应的Kendall、Spearman秩相关系数

```
Kendall_norm = copulastat("Gaussian",rho_norm)
Spearman_norm = copulastat("Gaussian",rho_norm,mode="Spearman")
```



```
Kendall_norm =
2x2 Matrix{Float64}:
 1.0      0.754266
 0.754266 1.0
```

```
Spearman_norm =
2x2 Matrix{Float64}:
 1.0      0.919818
 0.919818 1.0
```

```
Kendall =
2x2 Matrix{Float64}:
 1.0      0.757242
 0.757242 1.0
```

```
Spearman =
2x2 Matrix{Float64}:
 1.0      0.912626
 0.912626 1.0
```

- 求二元t-Copula对应的Kendall、Spearman秩相关系数

```
Kendall_t = copulastat("t",rho_t)
Spearman_t = copulastat("t",rho_t,nuhat,mode="Spearman")
```



```
Kendall_t =
2x2 Matrix{Float64}:
 1.0      0.764823
 0.764823 1.0
```

```
Spearman_t =
2x2 Matrix{Float64}:
 1.0      0.917924
 0.917924 1.0
```

对比数据，可以看出，Kendall_norm更接近 Kendall，Spearman_norm 更接近 Spearman，说明了线性相关参数为 $\hat{\rho} = 0.9264$ 的二元正态 Copula较好的反映了沪、深两市日收益率之间的秩相关性

建立知识规范，营造协同生态

积累工业模型，发展可控平台

融入中国创新，打造先进软件

感谢聆听

苏州同元软控信息技术有限公司
版权所有，侵权必究。

未经许可不得复制、传播或以其他方式使用；