


Syslab中的统计技术

汇报人：王慧敏

职位：培训讲师

日期：2025.07

©苏州同元软控信息技术有限公司版权所有，未经许可，不得复印、传播或以其他方式使用
版权所有，侵权必究



CONTENTS

目录 →



导论-一些统计中的概念



随机数



概率密度与累计概率分布



参数估计



假设检验

@苏州同元软控信息技术有限公司版权所有，侵权必究

未经许可，不得复印、传播或以其他方式使用

01



PART 01 ➔

一些统计中的概念

@苏州同元软控信息技术有限公司版权所有，未经许可，不得复印、传播或以其他方式使用
版权所有，侵权必究

一些统计中的概念-描述性统计量

调用格式	解释
mean(X), mean(A,dim)	X为向量; A为矩阵, 返回A中各列元素的平均值构成的向量; dim给出的维数内的平均值; 算术平均值数学含义, 即样本均值。
geomean(A)	几何平均数的数学含义是, 其中样本数据非负, 主要用于对数正态分布。几何平均数仅适用于具有等比或近似等比关系的数据。
harmmean(A)	调和平均值的数学含义是, 其中: 样本数据非0, 主要用于严重偏斜分布
median (M)	中位数将样本观测值从小到大依次排列, 位于中间的那个观测值, 称为样本中位数, 它描述了样本观测数据的中间位置。
mode (X)	众数描述了样本数据中出现次数最多的数
ty_quantile和prctile	一个用小数表示分位数, 一个用百分数表示分位数。 分位数就是先把一系列数按从小到大排序, 如果一共有n个数, 四分之一分位数就是第 $n*0.25$ 个数, 四分之三分位数就是第 $n*0.75$ 个数, 以此类推
skewness	样本的偏斜度, 偏度系数度量对称性。0说明是最完美的对称性, 正态分布的偏态就是0。右偏态为正, 表明平均值大于中位数。反之为左偏态, 为负
kurtosis	用来衡量数据尾部分散性, 它反映了分布曲线的陡缓程度。正态分布峰度为3, 可用来检验分布的正态性, 峰度 >3 , 则厚尾, 峰值附近陡峭; 峰度 <3 , 则细尾, 峰值附近平缓
ty_cov	协方差代表了两个变量之间的是否同时偏离均值。正值, 一个变量变大另一个变量也变大; 负值, 一个变量变大另一个变量变小, 取0说明两个变量没有相关关系
corrcoef	表示线性相关的方向, 还表示线性相关的程度, 取值 $[-1,1]$ 。通常情况下, 当相关系数的绝对值大于 $2/\sqrt{N}$, N为样本点的数量时, 我们认为线性关系是存在的。



01

PART 02 ➔

随机数

@苏州同元软控信息技术有限公司版权所有，未经许可，不得复印、传播或以其他方式使用
版权所有，侵权必究

通用函数求各项分布的随机数据

控制随机数的生成-以梅森旋转算法为例

Syslab在用随机数的时候把种子传进去，所以需要
先定义随机数种子;这也是和matlab不一样的地方。

```
julia> seed=MT19937ar(5489)
MT19937ar(5489)
```

```
julia> rand(seed,2,2)
2×2 Matrix{Float64}:
0.814724  0.126987
0.905792  0.913376
```

```
julia> rand(seed,2,2)
2×2 Matrix{Float64}:
0.632359  0.278498
0.0975404 0.546882
```

%matlab生成梅森旋转随机数种子

```
>> rng("default")
>> rand(2,2)
```

ans =

```
0.8147    0.1270
0.9058    0.9134
```

伪随机数、种子等算法函数

函数名称	功能
rand	区间 (0, 1) 均匀分布随机数
randn	正态分布随机数, 均值0, 方差1
randi	均匀分布的伪随机整数
randperm	随机序列
randpermk	随机整数序列
sprand	稀疏均匀分布随机矩阵

函数名称	算法
MCG16807	乘法同余生成器
MT19937ar	梅森旋转
DSFMT19937	面向 SIMD 的快速梅森旋转算法
SHR3	移位寄存器生成器与线性同余生成器求和
SWB2712	修正的借位减法生成器

通用函数求各项分布的随机数据

求指定分布的随机数：函数random

R= random(__,sz1,...,szN) 使用任何先前语法的输入参数从指定的概率分布生成随机数数组，其中 sz1, ..., szN 表示每个维度的大小

创建正态分布对象并使用该对象生成一个随机数。创建一个正态分布对象，平均 μ 等于 1，标准偏差 σ 等于 5。

```
using TyStatistics
mu = 1
sigma = 5
pd = Normal(mu,sigma)
rng = MT19937ar(5489)
r = random(rng,pd)
#3.6883356977305
```

分布对象	用于创建概率分布对象的函数
BetaDistribution	Beta
BinomialDistribution	Binomial
Chi-SquareDistribution	Chisq
BirnbaumSaundersDistribution	Birnbaum
BurrDistribution	Burr
ExponentialDistribution	Exponential
ExtremeValueDistribution	ExtremeValue
GammaDistribution	Gamma
GeneralizedExtremeValueDistribution	GeneralizedExtremeValue
GeneralizedParetoDistribution	GeneralizedPareto
HalfNormalDistribution	HalfNormal
HypergeometricDistribution	Hypergeometric
InverseGaussianDistribution	InverseGaussian
LoglogisticDistribution	Loglogistic
LognormalDistribution	LogNormal
LoguniformDistribution	Loguniform
NakagamiDistribution	Nakagami
NegativeBinomialDistribution	NegativeBinomial
NoncentralFDistribution	NoncentralF
NoncentralTDistribution	NoncentralT
NoncentralChi-SquareDistribution	NoncentralChisq
NormalDistribution	Normal
PoissonDistribution	Poisson
RayleighDistribution	Rayleigh
RicianDistribution	Rician
StableDistribution	Stable
TriangularDistribution	TriangularDist
Student t 分布	TDist
UniformDistribution	Uniform
WeibullDistribution	Weibull

常见分布随机数

常见的分布随机数的组成为：分布+rnd

函数名称	调用形式	注解
unifrnd	unifrnd(A,B,m,n)	[A,B]上均匀分布(连续)随机数
unidrnd	unidrnd(N,m,n)	均匀分布（离散）随机数
exprnd	exprnd(Lambda,m,n)	参数为Lambda的指数分布随机数
normrnd	normrnd(MU,SIGMA,m,n)	参数为MU, SIGMA的正态分布随机数
chi2rnd	chi2rnd(N,m,n)	自由度为N的卡方分布随机数
trnd	trnd(N,m,n)	自由度为N的t分布随机数
frnd	frnd(N1,N2,m,n)	第一自由度为N1,第二自由度为N2的F分布随机数
gamrnd	gamrnd(A,B,m,n)	参数为A,B的分布 γ 随机数
betarnd	betarnd(A,B,m,n)	参数为A,B的分布 β 随机数
lognrnd	lognrnd(MU,SIGMA,m,n)	参数为MU,SIGMA的对数正态分布随机数
nbinrnd	nbinrnd(R, P,m,n)	参数为R, P的负二项式分布随机数
ncfrnd	ncfrnd(N1, N2, delta,m,n)	参数为N1, N2, delta的非中心F分布随机数
nctrnd	nctrnd(N, delta,m,n)	参数为N, delta的非中心t分布随机数
ncx2rnd	ncx2rnd(N, delta,m,n)	参数为N, delta的非中心卡方分布随机数
raylrnd	raylrnd(B,m,n)	参数为B的瑞利分布随机数
weibrnd	weibrnd(A, B,m,n)	参数为A, B的韦伯分布随机数
binornd	binornd(N,P,m,n)	参数为N, p的二项分布随机数
geornd	geornd(P,m,n)	参数为p的几何分布随机数
hygernd	hygernd(M,K,N,m,n)	参数为M, K, N的超几何分布随机数
poissrnd	poissrnd(Lambda,m,n)	参数为Lambda的泊松分布随机数

常见分布随机数-均匀分布随机数验证大数定理和中心极限定理


#均匀分布随机数验证大数定律：样本均值收敛到总体均值

```
using TyStatistics
sz = 1000
#2和5的期望为3.5
mv1=mean(unifrnd(2, 5, sz))
mv=[mv1]
for k = collect(2000:1000:1e6)
    R = mean(unifrnd(2, 5, Int64(k)))
    global mv
    mv=push!(mv, R)
end
subplot(1,2,1)
plot(mv)
hold("on")
ezplot(y -> 3.5, [0, 1010])
legend(["大数", "y=3.5"])
title("验证大数定理结果")
```

#验证中心极限定理

```
clt=zeros(1000)
for i in 1:1000
    R=unifrnd(2,5,1000)
    global clt
    clt[i]=mean(R)
end
subplot(1,2,2)
histfit(clt,20)
title("验证中心极限定理结果")
```


- 大数定律讲的是样本均值收敛到总体均值（期望）
- 中心极限定理，当样本量足够大时，样本均值的分布服从正态分布



常见分布随机数-二项分布与泊松分布

泊松定理：若随机变量 $X \sim B(n, p)$ ，则当 n 比较大， p 比较小时，令 $\lambda = np$ ，则有

$$P\{X = k\} = C_n^k p^k (1-p)^{n-k} \approx \frac{\lambda^k}{k!} e^{-\lambda}$$



传播或以其他形式使用

©苏州同元软控信息技术有限公司版权所有，未经许可，不得复印、传播或以其他形式使用

03

PART 03 ➔

概率密度与累计概率分布



©苏州同元软件技术有限公司版权所有，未经许可，不得复印、传播或以其他方式使用
版权所有，侵权必究

通用函数计算概率密度值

通用函数pdf (probability density function) 计算概率密度函数值

- $Y = \text{pdf}(\text{name}(A), K)$
- $Y = \text{pdf}(\text{name}(A, B), K)$
- $Y = \text{pdf}(\text{name}(A, B, C), K)$

说明：返回在 $X = K$ 处、参数为A、B、C的**概率密度值**，对于不同的分布，参数个数是不同；name为分布函数名，其取值如常见分布函数表。



概率密度函数是分布函数的导函数

通用函数计算概率密度值

例1：计算正态分布N(0,1)的随机变量x在点0.6578的密度函数值。

```
using TyStatistics
np=pdf(Normal(0,1),0.6578)
#0.3213292587994887
#直接正态分布的公式计算
x=0.6578
np1=1/(sqrt(2*pi)*1)*exp(-(x-0)^2/2/(1^2))
#0.3213292587994887
```

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

例2：自由度为8的卡方分布，在点2.18处的密度函数值。

```
using TyStatistics
cp=pdf(Chisq(8),2.18)
#0.03628417580237809
```

$$f(x,k) = \frac{x^{\frac{k}{2}-1} e^{-\frac{x}{2}}}{2^{\frac{k}{2}} \Gamma(\frac{k}{2})}$$

K是自由度
Γ 是gamma函数

专用函数计算概率密度值

函数名	注释
unifpdf	[a,b]上均匀分布(连续)概率密度在 $X=x$ 处的函数值
unidpdf	均匀概率密度函数值
exppdf	参数为Lambda的指数分布概率密度函数值
normpdf	参数为mu, sigma的正态分布概率密度函数值
chi2pdf	自由度为n的卡方分布概率密度函数值
tpdf	自由度为n的t分布概率密度函数值
binopdf	参数为n, p的二项分布的概率密度函数值
poisspdf	参数为lamda的泊松分布的概率密度函数值
geopdf	参数为p的几何分布的概率密度函数值
wblpdf	参数为a, b的韦伯分布的概率密度函数值

例3: 某人射击的命中率为0.02, 他独立射击400次, 试求其命中次数不少于2次的概率

#二项分布

```
x1=binopdf(0,400,0.02)
```

```
x2=binopdf(1,400,0.02)
```

```
x=1-x1-x2
```

```
#0.9971654733929232
```

#泊松分布近似lamda=400*0.02=8

```
y1=poisspdf(0,8)
```

```
y2=poisspdf(1,8)
```

```
y=1-y1-y2
```

```
#0.9969808363488774
```

通用函数计算累积概率值

通用函数cdf计算随机变量 $X \leq K$ 的概率之和（累积概率值）

- $Y = \text{cdf}(\text{name}(A), K)$
- $Y = \text{cdf}(\text{name}(A, B), K)$
- $Y = \text{cdf}(\text{name}(A, B, C), K)$

说明：返回在 $X = K$ 处、参数为A、B、C的**累积概率**，对于不同的分布，参数个数是不同；name为分布函数名，其取值如常见分布函数表。


设离散型随机变量 X 的分布律是

$$P\{X = X_k\} = p_k \quad k = 1, 2, 3, \dots$$

则 $F(x) = P(X \leq x) = \sum_{x_k \leq x} p_k$ 。

由于 $F(x)$ 是 X 取 $\leq x$ 的诸值 x_k 的概率之和，故又称 $F(x)$ 为累积概率函数。

离散型随机变量



$F(x)$ 就代表概率分布函数，本质就是**概率函数取值的累加结果**所以它又叫累积概率函数

通用函数计算累积概率值



例：求标准正态分布随机变量 X 落在区间 $(-\infty, 0.4)$ 内的概率（该值就是概率统计教材中的附表：标准正态数值表在0.4的概率）。

```
using TyStatistics
p=cdf(Normal(0,1),0.4)
#0.6554217416103242
#0.2<x<0.4范围内的累计概率值
pp=cdf(Normal(0,1),0.4)-cdf(Normal(0,1),0.2)
#0.0761620321712212
#绘制该分布的直方图
normspec([0.2,0.4],0,1)
```

```
using TyStatistics
pd = makedist("Normal")#生成指定分布的对象
p1=cdf(pd,0.4)
#0.6554217416103242
```

例：求自由度为16的卡方分布随机变量落在 $[0, 6.91]$ 内的概率。

```
cp=cdf(Chisq(16),6.91)
#0.025042986816262176
```




专用函数计算累积概率值

函数名	注释
unifcdf	[a,b]上均匀分布(连续)概率密度在 $X=x$ 处的函数值
unidcdf	均匀概率密度函数值
expcdf	参数为Lambda的指数分布概率密度函数值
normcdf	参数为mu, sigma的正态分布概率密度函数值
chi2cdf	自由度为n的卡方分布概率密度函数值
tcdf	自由度为n的t分布概率密度函数值
binocdf	参数为n, p的二项分布的概率密度函数值
poisscdf	参数为lamda的泊松分布的概率密度函数值
geocdf	参数为p的几何分布的概率密度函数值
wblcdf	参数为a, b的韦伯分布的概率密度函数值

某人向空中抛硬币100次，落下为正面的概率为0.5。
这100次中正面向上的次数记为 X ：

- (1)试计算 $x = 45$ 的概率和 $x \leq 45$ 的概率；
- (2)绘制分布函数图和分布律图象。

```
#计算x=45的概率值
px=binopdf(45,100,0.5)
fx=binocdf(45,100,0.5)
#计算x≤45的累积概率值
subplot(1,2,1)
x=1:100
p1=binocdf(x,100,0.5)
plot(x,p1,"*")
title("累积分布函数图")
subplot(1,2,2)
x=1:100
p1=binopdf(x,100,0.5)
plot(x,p1,"-r")
title("分布律函数图")
```



联合分布函数例题

设二维随机变量 (X, Y) 的密度函数为

$$f(x, y) = \begin{cases} ce^{-(3x+4y)}, & x > 0, y > 0 \\ 0, & \text{otherwise} \end{cases}$$

[边缘概率密度,条件概率密度,边缘分布函数,联合分布函数关系【二维随机变量概念关系整理】最形象、透彻解释【概率论与数理统计】小元老师,心一学长_哔哩哔哩_bilibili](#)

- (1) 求常数 c ;
- (2) 求 (X, Y) 的联合分布函数;
- (3) 求 $P\{0 < X < 1, 0 < Y < 2\}$;
- (4) $P\{X + Y \geq 1\}$;
- (5) 边缘分布 $f_X(x)$

(1) 常数 $c=12$

(2) (X, Y) 的联合分布函数;

$$1 - \exp(-3x) - \exp(-4y) + \exp(-3x - 4y)$$

(3) 求 $P\{0 < X < 1, 0 < Y < 2\}$

$$P=0.9498941707050237$$

(4) $P\{X + Y \geq 1\}$;

$$P=0.14420135680525326$$

(5) 边缘分布 $f_X(x)$

$$3\exp(-3x)$$

04

PART 04 ➔

参数估计


@苏州同元软控信息技术有限公司版权所有，未经许可，不得复印、传播或以其他方式使用
版权所有，侵权必究

参数估计

统计学有两大主要分支，分别是**描述性统计学**和**推断统计学**。

- 描述性统计学用于描述和概括数据的特征以及绘制各类统计图表。
- 总体数据，往往因为数据量太大而难以被获取，所以就有了通过较小的样本数据推测总体特性的推断统计学，如参数估计、假设检验等。

- 在很多实际的问题中，为了进行某些统计判断，需要确定**总体所服从的分布**，通常根据问题的实际背景或适当的统计方法可以判断总体分布的类型，但是总体分布中往往含有未知参数，需要用样本观测数据进行估计。
- 例如：学生的某门课程的考试成绩通常服从正态分布 $N(\mu, \sigma^2)$ ，其中 μ 和 σ 是未知参数，就需要用样本观测数据进行估计，这就是所谓的参数估计，它是统计推断的一种重要形式。



正态分布图，X轴以标准差为刻度



常用分布的参数估计

调用形式	函数说明
PHAT,PCI=binofit(X,N,alpha)	二项分布，置信度为95%的参数估计和置信区间，返回水平 α 的参数估计和置信区间
Lambdahat,Lambdaci=poissfit(X,alpha)	泊松分布，置信度为95%的参数估计和置信区间，返回水平 α 的 λ 参数和置信区间
muhat,sigmahat,muci,sigmaci=normfit(X,alpha)	正态分布的最大似然估计，置信度为95%，返回水平 α 的期望、方差值和置信区间
PHAT,PCI=betafit(X,alpha)	返回 β 分布参数a和b的最大似然估计，返回最大似然估计值和水平 α 的置信区间

例1：分别使用金球和铂球测定引力常数

- (1) 用金球测定观察值为：6.683 6.681 6.676 6.678 6.679 6.672
- (2) 用铂球测定观察值为：6.661 6.661 6.667 6.667 6.664
- 若滚珠服从正态分布，设测定值总体为 $N(\mu, \sigma^2)$ ， μ 和 σ 为未知。对(1)、(2)两种情况分别求 μ 和 σ 的置信度为0.9的置信区间。

```
using TyStatistics
X=[6.683, 6.681 ,6.676, 6.678, 6.679, 6.672]
Y=[6.661, 6.661, 6.667, 6.667, 6.664]
mu,sigma,muci,sigmaci=normfit(X,0.1)
mu1,sigma1,muci1,sigmaci1=normfit(Y,0.1)
```

```
情况1：金球测定的结果
6.678166666666666, 0.003868677637987827
[6.674984137487131; 6.681349195846201;;]
[0.002599943871787033; 0.008082663626959216;;]
情况2：铂球测定的结果
6.664, 0.00300000000000001137
[6.661139827400895; 6.66860172599105;;],
[0.0019479155021567764; 0.007117067074229534;;]
```

参数估计-mle函数

最大似然估计 (MLE): Maximum likelihood estimates

phat, pci = mle(data) 使用样本数据 data 返回正态分布参数的最大似然估计 (MLE)。

phat, pci = mle(data; Name=Value) 使用一个或多个关键字参数指定选项。

例如, 您可以使用以下关键字参数之一指定分布类型: dist、pdf、logpdf 或 nloglf。

要计算内置分布的 MLE, 请使用 dist 指定分布类型。例如, dist="Beta" 指定计算 beta 分布的 MLE。

要计算自定义分布的 MLE, 请使用 pdf、logpdf 或 nloglf 定义分布, 并使用 start 指定初始参数值。

#mle函数的参数估计

using TyStatistics

X=[6.683, 6.681, 6.676, 6.678, 6.679, 6.672]

phat,pci=mle(X;dist="Normal", alpha=0.1)

#[6.678166666666666, 0.003531603350069563],

#[6.674984137487131 0.002599943871787033;

6.681349195846201 0.008082663626959216

已知总体X的密度函数为

$$f(x;\theta)=\begin{cases}\theta x^{\theta-1}, & 0 < x < 1 \\ 0, & otherwise\end{cases}$$

其中 θ 是未知参数。现从总体X中随机抽取容量为20的样本, 得样本观测值如下:

0.7917	0.8448	0.9802	0.8481	0.7627	0.9013	0.9037	0.7399	0.7843	0.8424
0.9842	0.7134	0.9959	0.6444	0.8362	0.7651	0.9341	0.6515	0.7956	0.8733

试根据以上样本观测值求参数 θ 的最大似然估计和置信水平为95%的置信区间。

using TyStatistics

x = [0.7917, 0.8448, 0.9802, 0.8481, 0.7627, 0.9013, 0.9037, 0.7399, 0.7843, 0.8424, 0.9842, 0.7134, 0.9959, 0.6444, 0.8362, 0.7651, 0.9341, 0.6515, 0.7956, 0.8733];

pdf=(x,theta)->theta*x.^(theta-1).*convert.(Float64,(0 .<x .<1))

phat,pci=mle(x,pdf=pdf,start=1)

#[5.150183105468758, [2.8930573468402616; 7.407308864097253;;]]

参数估计-mle函数

例：某校60名学生的一次考试成绩如下：

- 1) 计算均值、标准差、极差、偏度、峰度，画出直方图；
- 2) 检验分布的正态性；
- 3) 若检验符合正态分布，估计正态分布的参数并检验参数。


93	75	83	93	91	85	84	82	77	76
77	95	94	89	91	88	86	83	96	81
79	97	78	75	67	69	68	84	83	81
75	66	85	70	94	84	83	82	80	78
74	73	76	70	86	76	90	89	71	66
86	73	80	94	79	78	77	63	53	55

```
using TyStatistics
score = [93, 75, 83, 93, 91, 85, 84, 82, 77, 76, 77,
95, 94, 89, 91, 88, 86, 83, 96, 81, 79, 97, 78, 75, 67,
69, 68, 84, 83, 81, 75, 66, 85,
70, 94, 84, 83, 82, 80, 78, 74, 73, 76, 70, 86, 76,
90, 89, 71, 66, 86, 73, 80, 94, 79, 78, 77, 63, 53, 55]
stats = [mean(score), var(score), range(score),
skewness(score), kurtosis(score)]
```

```
stats = 80.1000 94.2949 44.0000 -0.4682
[3.1529]
```

参数估计-mle函数

```
using TyStatistics
score = [93, 75, 83, 93, 91, 85, 84, 82, 77, 76, 77, 95, 94, 89, 91,
88, 86, 83, 96, 81, 79, 97, 78, 75, 67, 69, 68, 84, 83, 81, 75, 66,
85,
70, 94, 84, 83, 82, 80, 78, 74, 73, 76, 70, 86, 76, 90, 89, 71,
66, 86, 73, 80, 94, 79, 78, 77, 63, 53, 55]
stats = [mean(score), var(score), range(score), skewness(score),
kurtosis(score)]
subplot(2,1,1)
histfit(score,15)#近似正态分布
title("附加正态密度曲线的直方图")
subplot(2,1,2)
normplot(score)#略有后尾特性
phat,pci=mle(score;dist="Normal", alpha=0.05)
#([80.1, 9.62929557825147], [77.59149715696078 8.230998683675944;
82.6085028430392 11.843596638015313])
```



05

PART 05 →

假设检验

©苏州同元软控信息技术有限公司版权所有，未经许可，不得复印、传播或以其他方式使用
版权所有，侵权必究

正态总体参数检验

常用正态总体参数检验	函数	说明
Z检验	ztest	已知总体 σ^2 ，单个正态总体的均值 μ 的假设检验，函数ztest
单样本和配对样本 t 检验	ttest	未知总体 σ^2 ，单个正态总体的均值 μ 的假设检验
双样本t检验	ttest2	两个正态总体方差未知但等方差时，比较两正态总体样本均值的假设检验（t检验）
卡方方差检验	vartest	总体均值未知时的单个正态总体方差的卡方检验（ χ^2 检验法）
相等方差的双样本 F 检验	vartest2	总体均值未知时的两个正态总体方差的比较F检验
检验功效与样本容量的计算	sampsizepwr	给定其他两个值，计算假设检验的样本大小、功效或备选参数

苏州同元软控信息技术有限公司版权所有，侵权必究。未经许可，不得转载或以其他形式使用。

Z检验法

已知 σ_2 ，单个正态总体的均值 μ 的假设检验，函数ztest

$h, p, ci, zval = \text{ztest}(x, m, \text{sigma}, \alpha=0.05, \text{tail}=: \text{both}, \text{dim}=\text{Int}[])$: x 为正态总体的样本， m 为均值 μ_0 ， sigma 为标准差，显著性水平为 α (默认0.05)； p 为观察值的概率，当 p 为小概率时则对原假设提出质疑， ci 为真正均值 μ 的 $1-\alpha$ 置信区间， $zval$ 为统计量的值。

若 $h=0$ ，表示在显著性水平 α 下，不能拒绝原假设；

若 $h=1$ ，表示在显著性水平 α 下，可以拒绝原假设。

原假设： $H_0: \mu = \mu_0 = m$

$\text{tail}=: \text{both}$ ，表示备择假设： $H_1: \mu \neq \mu_0 = m$ （默认，双边检验）；

$\text{tail}=: \text{right}$ ，表示备择假设： $H_1: \mu > \mu_0 = m$ （单边检验）；

$\text{tail}=: \text{left}$ ，表示备择假设： $H_1: \mu < \mu_0 = m$ （单边检验）。

Z检验法例题

例：某车间用一台包装机包装葡萄糖，包得的袋装糖重是一个随机变量，它服从正态分布。当机器正常时，其均值为0.5公斤，标准差为0.015。某日开工后检验包装机是否正常，随机地抽取所包装的糖9袋，称得净重为（公斤）0.497, 0.506, 0.518, 0.524, 0.498, 0.511, 0.52, 0.515, 0.512，问机器是否正常？

解：总体 μ 和 σ 已知，该问题是当 σ^2 为已知时，在水平 $\alpha = 0.05$ 下，根据样本值判断 $\mu = 0.5$ 还是 $\mu \neq 0.5$ 。为此提出假设：原假设： $H_0: \mu = \mu_0 = 0.5$ 备择假设： $H_1: \mu \neq \mu_0 = m$

```
using TyStatistics
X = [0.497, 0.506, 0.518, 0.524, 0.498, 0.511,
0.52, 0.515, 0.512]
h, p, ci, zval = ztest(X, 0.5, 0.015)
```



```
julia> h
1.0
julia> p
0.02480381963225592
julia> ci
2-element Vector{Float64}:
 0.5014224022995221
 0.5210220421449226
julia> zval
2.2444444444444471
```

结果表明： $h=1$ ，说明在水平 $\alpha=0.05$ 下，可拒绝原假设，即认为包装机工作不正常。

检验功效与样本容量的计算

- 假设检验的两类错误
- 第一类错误是“**弃真**”错误，第Ⅰ类错误概率 = $P(\text{拒绝}H_0 \mid H_0\text{为真}) \leq \alpha$ 。拒绝 H_0 时可能犯第Ⅰ类错误；若 H_0 无病， H_1 有病，则第Ⅰ类错误属于误诊。反之，结论正确。
- 第二类错误是“**取伪**”错误，第Ⅱ类错误概率 = $P(\text{不拒绝}H_0 \mid H_1\text{为真}) \leq \beta$ 。不拒绝 H_0 时可能犯第Ⅱ类错误。若 H_0 无病， H_1 有病，则第Ⅱ类错误属于漏诊。反之，即功效 = $P(\text{拒绝}H_0 \mid H_1\text{为真}) \geq 1 - \beta$ 。
- 假设检验需要控制犯两类错误的概率均在一个较低的水平
- 实际上在样本容量固定的前提下，降低 α 的同时会增加 β ，降低 β 的同时 α 也会增加，为了平衡这一矛盾，提出了显著性检验的概念，也就是**在控制犯第一类错误的概率不超过某一水平（即显著性水平）的前提下制约 β** 。

		真实情况	
		原假设成立	原假设不成立
依据样本得到的检验结论	拒绝原假设	第一类错误 概率为 α	正确结论 概率为 $1 - \beta$
	不能拒绝原假设	正确结论 概率为 $1 - \alpha$	第二类错误 概率为 β



检验功效与样本容量的计算

- 检验功效与样本容量的关系
- 原假设不成立的条件下，拒绝原假设的概率（即 $1 - \beta$ ）称为检验的功效。功效即假设检验发现真实差异的功效就不低于 $1 - \beta$ ，即：

检验功效 = $P(\text{拒绝}H_0 \mid H_1 \text{为真}) \geq 1 - \beta$ ，检验功效 = $P(\text{拒绝}H_0 \mid H_0 \text{为假}) \geq 1 - \beta$ ；

- 检验功效反映了一个显著性检验能够区分原假设和备择假设的能力；通常情况下，应使得检验功效达到一个较高的水平（如90%以上）。
- 当给定样本容量时可以求得检验功效，**样本容量越大，检验功效越高**，即区分原假设与备择假设的能力越强；反之，给定检验功效，也可求出样本容量。
- 调用sampsizewr函数求样本容量和检验功效。

检验功效与样本容量的计算

调用sampsizewr函数求样本容量和检验功效，格式：

nout= sampsizewr(testtype,p0,p1) 返回样本大小 nout，这使得由 testtype 指定的类型的双侧检验具有 0.90 的功效（当备择假设为真时拒绝原假设的概率）以及 0.05 的显著性水平（当备择假设为真时拒绝原假设的概率原假设为真）。p0 指定原假设下的参数值。p1 指定在备择假设下测试的单个参数的值或数组

n=sampsizewr (testtype, p0, p1, power)：求样本容量，用power参数指定参数功效，其值介于0-1之间；

- power=sampsizewr (testtype, p0, p1, [], n)：给定样本容量n，求检验功效power；
- p1=sampsizewr (testtype, p0, [], power, n)：给定样本容量n和检验功效power，求备择假设中的参数p1；
- [...]=sampsizewr (... , n, param1, val1, param2, val2, ...)：用可选的成对出现的参数名和参数值控制计算结果

z	标准差已知时，正态总体均值的检验	p0是形如[u0,a0]的向量，其元素分别为原假设对应的总体均值和标准差。p1是备择假设对应的总体均值。
t	标准差未知正态总体，均值的检验	p0是形如[u0,a0]的向量，其元素分别为原假设对应的总体均值和样本标准差，p1是备择假设对应的总体均值。
var	正态总体的方差检验	p0和p1分别是原假设和备择假设对应的总体方差。
p	二项分布的比例（成功概率）检验	p0和p1分别是原假设和备择假设对应的参数值。当参数p1为向量时，输出参数n是与p1等长的向量。

检验功效与样本容量的计算

例：设需要对某一正态总体的均值进行如下检验：


$H_0: \mu = 100$, $H_1: \mu > 104$

已知总体标准差 $\sigma = 6.58$ ，取显著性水平 $\alpha = 0.05$ ，同时要求检验功效达到90%以上，求所需要的样本容量。

```
using TyStatistics
mu0 = 100; #原假设对应的总体均值
sigma0 = 6.58; #原假设对应的标准差
p0=[mu0,sigma0]
mu1 = 104; #备择假设对应的总体均值
p1=mu1
pow = 0.9; #检验功效
#调用sampsizewr函数求样本容量
n=sampsizewr("z",p0,p1,pow,tail="right")
#24
```

要检验功效达到90%以上，需要的样本容量至少为24，如果指定不同的样本容量，还可求得相应的检验功效。

```
n1= collect(10:60) #指定不同的样本容量
#调用sampsizewr函数求不同样本容量对应的检验功效
power=sampsizewr("z",p0,p1,nothing,n1,tail="right")
#调用sampsizewr函数求不同样本容量对应的检验功效
plot(n1,power,"r--",linewidth=3)
xlabel("样本容量")
ylabel("检验功效")
title("检验功效与样本容量的关系曲线")
```



非参数检验问题

在用样本数据对总体信息做出统计推断时，通常要求抽样应**满足随机性和独立性**，因为几乎所有的抽样定理都是建立在数据独立的基础之上的。

- 而在用样本数据对正态总体参数做出统计推断（例如参数估计和假设检验）时，还要附加一个要求：样本数据应服从正态分布，这种数据分布类型已知的总体参数的假设称为**参数假设检验**。
- 与参数假设检验相对应的还有**非参数假设检验**，例如分布的正态性检验，样本的随机性检验等，这类检验通常只假定分布是连续的或对称的，并不要求数据服从正态分布。
- 主要非参数检验：游程检验、符号检验、曼-惠特尼U检验、Wilcoxon符号秩检验。

优缺点与选择：

- 不受总体分布类性的限制，应用范围广泛，基本上每一种参数统计方法都有相应非参数统计方法对应；对数据的要求不象参数统计方法那样严格。
- 其不足之处是对符合用参数统计的资料，用非参数统计方法时，犯第二类错误的概率 β 比参数统计方法要大，亦即 $(1 - \beta)$ 要小。
- 若要使其相同，非参数的方法比参数的方法所需要得样本含量更多。故适合参数统计条件的资料，通常首选参数统计，若应用条件不能满足，才用非参数统计的方法。

符号检验

符号检验：**通过符号“+”和“-”的个数来进行统计推断的方法**。符号检验是古老的检验方法之一。如果差异中正号的数目和负号的数目相差很大（超过临界值）则应拒绝原假设，否则应接受原假设。

- 简单符号检验应用简单且适用范围较广，但检验中失去的信息较多。
- 进行简单符号检验时，首先应计算两组样本的对应项之差，统计差为正和为负的数目，应注意对于可能出现的差为0的情况，应从样本中忽略，并相应地减少总的样本容量；然后在给定的显著性水平下，根据原假设进行假设检验。
- 当为小样本($n \leq 30$)时可用二项分布检验，当为大样本($n > 30$)时，可用正态分布检验。
- 统计量：

$$z = \frac{(S - E(S))}{\sqrt{V(S)}} = \frac{(S - 0.5)n - 0.5 \text{sign}(n_{\text{pos}} - n_{\text{neg}})}{0.5\sqrt{n}}$$

其中 n_{pos} 和 n_{neg} 分别是假设中值的正负差异数

符号检验

两个总体中位数相等的假设检验，函数signtest:

`p,h,stats = signtest(X, Y, alpha)` # X、Y为两个总体的样本，长度必须相同，P两个样本X和Y的中位数相等的概率，p接近于0则可对原假设质疑。h为检验结果：h=0表示X与Y的中位数之差不显著，h=1表示X与Y的中位数之差显著。stats中sign为符号统计量的值。

`p,h,stats=signtest(x,m,param1,val1,...)`: 双侧符号检验，原假设是x来自于中位数为m的连续分布，备择假设是x来自于中位数不为m的连续分布，此时用可选的成对出现的参数名和参数值来控制计算结果

例如：假设某城市16座预出售的楼盘均价(单位：千元/平方米) 如下表所示：

36	32	31	25	28	36	40	32
41	26	35	35	32	87	33	35

问：该地区平均楼盘价格是否与媒体公布的37000元/平方米的说法相等？

思考：如果原假设为真，即37是总体的中位数，则数据中应该差不多各有一半在37的两侧。计算每一个数据与37的差，用S+表示位于37右边的数，S-表示位于37左边点个数，即 $S \sim b(n, 0.5)$ 。从有利于接受备择假设的角度，S+过大或过小，都表示37不能作为总体的中心，这个思路就是符号检验的基本原理。

```
using TyStatistics
X = [36 32 31 25 28 36 40 32 41 26 35 35 32 87 33 35];
p,h,stats = signtest(X,37,method = "exact")
p=0.021270751953125007
h=true
stats=
TyStatisticsCore.__Internal__.Signtest
    sign: Int64 3
    zval: Float64 NaN
```

假设检验的结果，作为逻辑值返回。
•如果 h = 1，这表示在 100 * Alpha% 显著性水平下拒绝原假设。
•如果 h = 0，这表示无法拒绝 100 * Alpha% 显著性水平的原假设。

Thanks.

建立知识规范，营造协同生态
积累工业模型，发展可控平台
融入工业创新，共创先进软件

©苏州同元软控信息技术有限公司
版权所有，侵权必究

